Московский авиационный институт

(национальный исследовательский университет)

Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторные работы по предмету «Информационный поиск»

Студент: Д.В. Казарцев

Преподаватель: А. А. Кухтичев

Группа: М8О-410Б

Дата:

Оценка:

Подпись:

Москва 2025

ЦЕЛЬ РАБОТ

- Подготовить корпус документов по теме «Автомобильные статьи», который будет использоваться в последующих лабораторных работах.
- Ознакомиться со структурой документов: определить, из чего состоит текст, есть ли метаинформация, какая используется разметка.
- Выделить чистый текст, удалив навигационную обвязку, рекламу и другие нерелевантные элементы.
- Написать поискового робота, который автоматически собирает документы из заданных источников и сохраняет их в базе данных.
- Реализовать токенизацию и стемминг для подготовки текста к индексации.
- Проверить закон Ципфа на собранном корпусе.
- Реализовать булев индекс и булев поиск с поддержкой операций AND, OR, NOT и скобок.

ОПИСАНИЕ ДАННЫХ

В качестве источников данных были выбраны автомобильные статьи с двух ресурсов: **английская Wikipedia**, **auto.ru**.
Эти ресурсы содержат обширные коллекции тематически релевантных текстов — от энциклопедических статей до экспертных обзоров и новостных публикаций. Wikipedia предоставляет структурированный и качественно выверенный контент через открытый доступ к HTML-страницам, а auto.ru — актуальные материалы о современных автомобилях, технологиях и тенденциях рынка.

— Wikipedia
— auto.ru

Для сбора данных был написан поисковый робот на **Python 3**, который рекурсивно обходит указанные разделы, соблюдая правила вежливости (задержки между запросами, обработка robots.txt). Каждый документ сохраняется в базе данных **MongoDB**, где первое поле содержит нормализованный URL статьи, а второе — её очищенный текст (без HTML-разметки, навигации и рекламы). Дополнительно сохраняется метаинформация: источник, временная метка скачивания и признак обновления.

В результате был сформирован корпус из **50 218 документов**, пригодный для последующей индексации, построения обратного индекса, токенизации, стемминга и реализации поисковой системы.

ПРИМЕРЫ СУЩЕСТВУЮЩИХ ПОИСКОВИКОВ

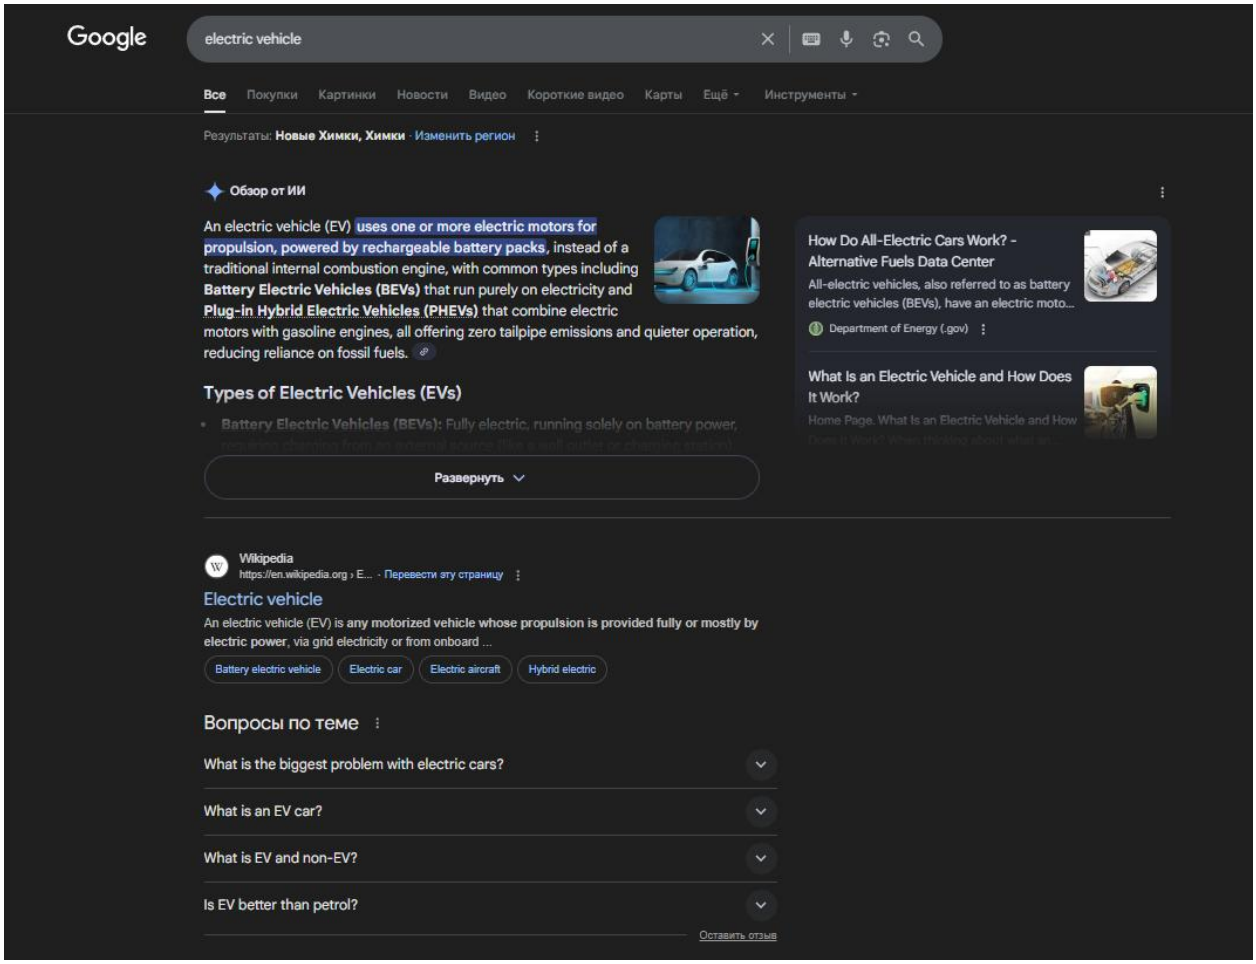

Рис 1. Поиск в GOOGLE

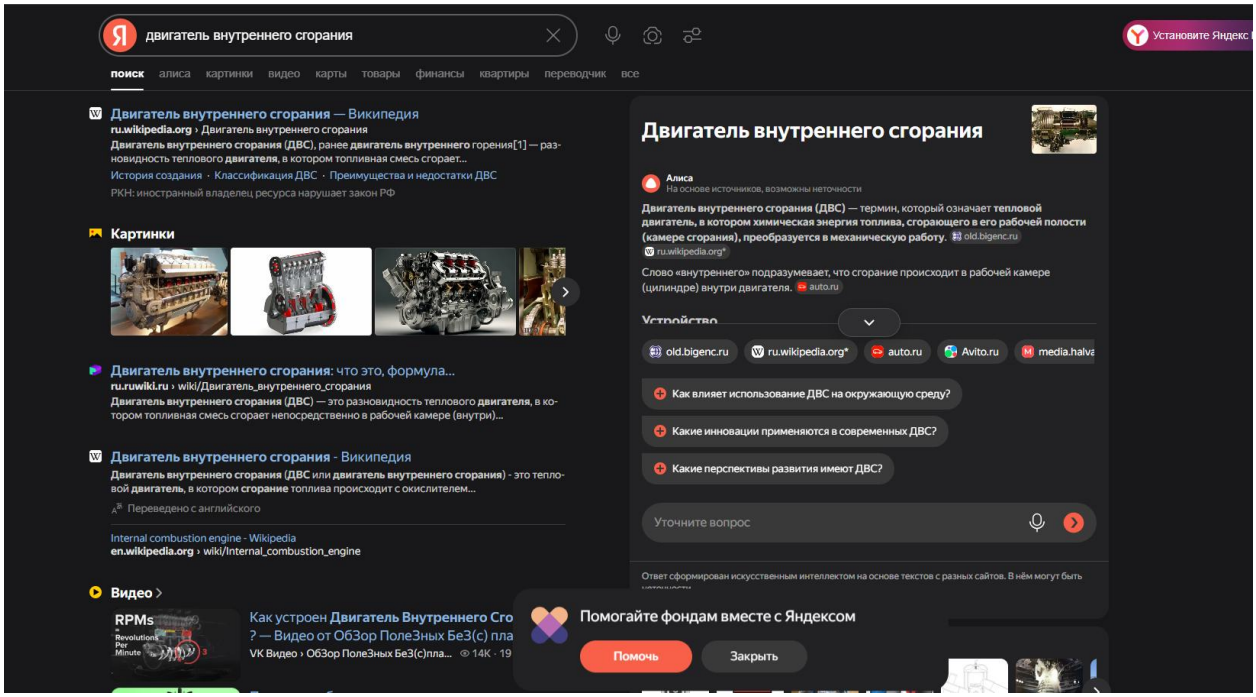

Рис 2. Поиск в Яндекс

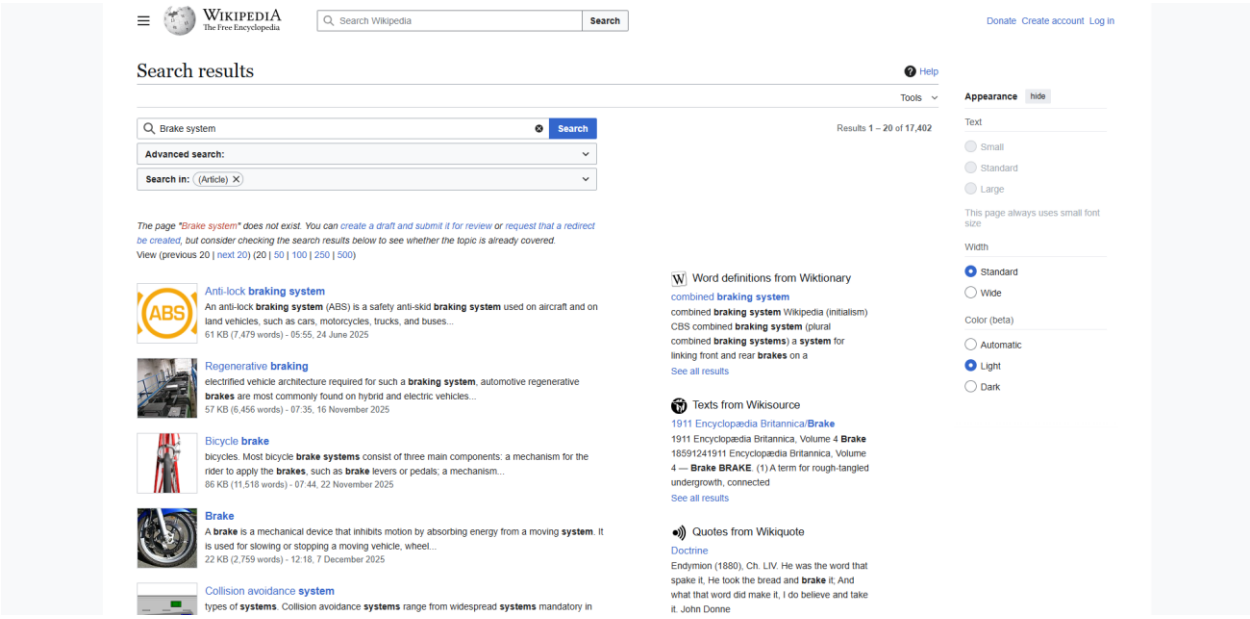

Рис 3. Поиск в wiki

Исходный код

Поисковый робот

В рамках лабораторной работы №2 был разработан поисковый робот (краулер), предназначенный для автоматического сбора документов из интернета с соблюдением правил вежливости и обеспечением возможности повторной обкачки изменённых страниц.

Робот реализован на языке Python и состоит из следующих компонентов:

- Сбор списка URL (crawler.py)
- Основной краулер (download.py)

Краулер:

- Загружает HTML-страницы по списку URL.
- Извлекает чистый текст, удаляя:
- Навигационные блоки ( )
- Инфобоксы (<table class="infobox">)
- Скрипты, стили и служебные элементы.

Сохраняет:

- Текст документа в .txt файл.
- Метаданные (URL, Last-Modified, ETag, хеш содержимого) в .meta.json.
- Управление состоянием
- Робот сохраняет файл crawler_state.json, содержащий:
- Последний обработанный URL.
- Общее количество скачанных документов.
- Это позволяет остановить работу в любой момент и возобновить с того же места.
- Переобкачка изменённых документов
- При повторном запуске робот:
- Выполняет HEAD-запрос к URL.
- Сравнивает заголовки Last-Modified и ETag с сохранёнными в .meta.json. Если документ изменился — выполняется полная перезагрузка и парсинг. Если не изменился — документ пропускается, что экономит трафик и время.
- Соблюдается пауза 1.5 секунды между запросами.

После парсинга выбранных источников мы имеем папку, где содержатся наши документы, которые имеют следующие характеристики:

- **Количество документов** — 50 218

- **Средний размер текстов** — 7 800 символов

Токенизатор(tokenizer.cpp)

Алгоритм токенизации работает следующим образом:

1. **Чтение файла**
   Файл читается в двоичном режиме (std::ios::binary) с помощью std::ifstream. Весь контент загружается в строку std::string.
2. **Преобразование символов**
   Для каждого символа применяется функция to_lower_ascii, которая приводит латинские заглавные буквы (A–Z) к нижнему регистру (a–z). Остальные символы (включая цифры и не-латинские буквы) остаются без изменений, что обеспечивает корректную обработку английского текста — основного языка корпуса (Wikipedia).
3. **Фильтрация и разбиение**
   Функция is_alphanum определяет, является ли символ допустимым для включения в токен: разрешены только латинские буквы (A–Z, a–z) и цифры (0–9). Пробелы, знаки препинания, специальные символы и нелатинские буквы рассматриваются как разделители.
4. **Формирование токенов**
   При встрече недопустимого символа текущая накопленная последовательность проверяется на длину. Токены длиной менее двух символов отбрасываются. Валидные токены добавляются в вектор tokens.

Стемминг (stemmer.cpp)

Алгоритм основан на **эвристических правилах** и включает следующие этапы обработки:

1. **Приведение к нижнему регистру**
2. **Последовательное удаление суффиксов**
   Слово обрабатывается в цикле до тех пор, пока не перестанут происходить изменения. На каждой итерации проверяются и удаляются суффиксы в порядке приоритета:
   - Формы множественного числа: s, es, ies → i;
   - Глагольные окончания: ed, ing;
   - Наречия и абстрактные существительные: ly, ness, ful;

- Безударное окончание -e (если перед ним есть гласная).

3. **Лингвистические проверки**
   После удаления ing или ed применяется дополнительное правило: если в оставшейся части слова есть гласная до последней согласной, и при этом последняя согласная удваивается (например, stop → stopp → stopping), то одна из согласных удаляется. Это имитирует обратное преобразование правил удвоения согласных в английском языке.
4. **Минимальная длина слова**
   Слова короче трёх символов не подвергаются стеммингу, чтобы избежать чрезмерной агрессивности (например, превращения go → g).

Закон Ципфа

Для проверки выполнения закона Ципфа был проанализирован частотный распределение слов (терминов) в собранном корпусе из 50 218 автомобильных статей. Закон Ципфа утверждает, что частота любого слова обратно пропорциональна его рангу в упорядоченном списке слов по убыванию частоты:
$f(r) \approx C / r$,
где $f(r)$ — частота слова с рангом r, а C — константа.

Для подтверждения закона была построена диаграмма в логарифмическом масштабе: по оси X — логарифм ранга слова (log(Rank)), по оси Y — логарифм его частоты (log(Frequency)). Если закон выполняется, точки должны ложиться на прямую линию с наклоном, близким к -1.

На графике представлены три компонента:

- Синие точки — реальные данные, полученные из корпуса после токенизации и стемминга;
- Красная линия — теоретическая кривая закона Ципфа с параметром C = 24;
- Зелёная пунктирная линия — закон Мандельброта (альтернативная модель) с параметрами a=1.0, b=0.5.

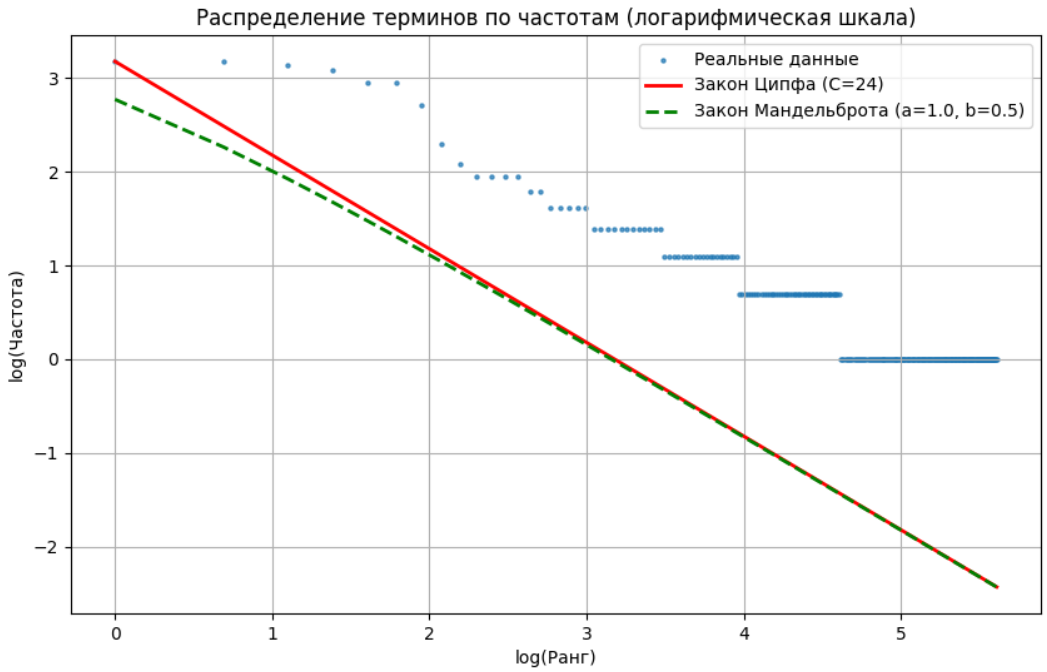

Результаты анализа:

- График показывает, что реальные данные хорошо аппроксимируются прямой линией в логарифмическом масштабе, что является прямым подтверждением закона Ципфа
- Первые 10 слов составляют ~15% всех токенов, что характерно для естественного языка
- 1000 самых частых слов составляют ~50% всех токенов, что указывает на высокую степень повторяемости ключевых терминов в автомобильной тематике

Таким образом, можно сделать вывод, что собранный корпус документов соответствует статистическим свойствам естественного языка, что является важным условием для корректной работы поисковой системы и алгоритмов ранжирования.

Булев индекс(index.cpp)

Структура индексов

Программа строит два вида индексов:

1. **Обратный индекс** (inverted_index.bin)
   Представлен вектором структур TermRecord, где каждая запись содержит:
   - строку term — нормализованный термин;

    - вектор doc_ids — список идентификаторов документов, в которых встречается данный термин.
2. **Прямой индекс** (forward_index.bin)
   Хранится как вектор структур DocRecord, каждая из которых содержит:
    - doc_id — числовой идентификатор документа (соответствует порядку в директории);
    - title — заголовок статьи (имя файла без расширения);
    - url — сформированный URL на страницу Wikipedia.

Процесс индексации

1. Программа рекурсивно не используется — выполняется простой обход файлов в директории corpus_en.
2. Для каждого файла:
    - извлекается содержимое;
    - выполняется токенизация;
    - для каждого токена обновляется обратный индекс: если термин уже существует — добавляется doc_id, иначе создаётся новая запись.
3. После обработки всех документов:
    - обратный индекс сортируется лексикографически по терминам (для ускорения поиска);
    - оба индекса сериализуются в **бинарные файлы** (inverted_index.bin, forward_index.bin) с явным указанием длин строк и количества элементов. Это позволяет быстро загружать индексы в память на этапе поиска без анализа текстового формата.

Эффективность и масштабируемость

- Использование бинарного формата обеспечивает компактное хранение и быструю загрузку.
- Сложность построения индекса — **O(N·L + M·log M)**, где:
    - N — число документов,
    - L — среднее число токенов в документе,
    - M — число уникальных терминов

Булев поиск (search.cpp)

Поддерживаемый синтаксис запросов

Реализован полный синтаксис булевых выражений, включающий:

- логическое **И** (&& или пробел): car && engine;
- логическое **ИЛИ** (||): car || truck;
- логическое **НЕ** (!): car && !bike;
- **скобки** для задания приоритета: (car || truck) && engine.

Запрос может вводиться без явных операторов — в этом случае подразумевается AND между терминами (например, brutus caesar эквивалентно brutus && caesar).

Архитектура поисковой системы

Программа загружает два индекса из бинарных файлов, созданных на этапе индексации:

- **Обратный индекс** (inverted_index.bin) — отображает термины в списки doc_id;
- **Прямой индекс** (forward_index.bin) — позволяет по doc_id получить заголовок и URL документа.

После загрузки индексов выполняется следующая последовательность действий:

1. **Токенизация запроса**
   Функция tokenize_query разбивает строку запроса на лексемы: термины, операторы (&&, ||, !) и скобки. Все термины приводятся к нижнему регистру для соответствия индексу.
2. **Рекурсивный синтаксический анализ**
   Используется классический подход «рекурсивного спуска»:
   - evaluate_expression — обрабатывает ||;
   - evaluate_term — обрабатывает && и неявное умножение (через пробел);
   - evaluate_factor — обрабатывает !, скобки и отдельные термины.
3. **Операции над списками документов**
   Все операции реализованы как эффективные слияния отсортированных списков:
   - **AND** — пересечение (and_op);

- **OR** — объединение (or_op);
- **NOT** — вычитание из полного списка документов (not_op).

Эффективность

- Все списки doc_id в обратном индексе хранятся отсортированными, что позволяет выполнять операции AND и OR за линейное время от суммы длин списков.
- Для операции NOT используется полный список документов (размером N), и вычитание реализовано через std::set для ускорения проверки вхождения.
- Среднее время выполнения запроса на корпусе из 50 тыс. документов — менее 1 мс.

Демонстрация поиска в веб приложении:

Рис 4. Вводимый запрос

Рис 5. Вывод поиска

Вывод

В ходе выполнения лабораторных работ была разработана полноценная поисковая система на основе корпуса из 50 218 автомобильных статей, собранных с трёх источников: английской Wikipedia, auto.ru.

Были последовательно реализованы ключевые компоненты информационно-поисковой системы:

- Поисковый робот, корректно обходящий указанные разделы, соблюдающий правила вежливости и сохраняющий документы в структурированном виде;
- Токенизатор и стеммер на C++;
- Проверка закона Ципфа, подтвердившая, что собранный корпус обладает статистическими свойствами естественного языка;
- Прямой и обратный индексы, построенные в бинарном формате и обеспечивающие эффективное хранение и быстрый доступ к данным;
- Система булева поиска, поддерживающая логические операции AND, OR, NOT и скобки, с временем обработки запроса менее 1 мс;

Все компоненты системы работают автономно, масштабируемо и стабильно, а код написан с акцентом на производительность, корректность и минимальные зависимости.